

# Aula 5: Propriedades estatísticas básicas dos modelos de Box e Jenkins

## Apresentação

---

Nesta aula calcularemos o valor esperado e a variância dos modelos ARMA, propostos por Box e Jenkins e apresentados na aula 4. Iniciaremos com uma revisão das fórmulas já apresentadas para os modelos mais simples (AR e MA de ordem 1) e, em seguida, veremos as expressões para os modelos AR e MA de ordens mais avançadas e para a classe geral ARMA.

# Objetivos

- Declarar o valor esperado e a variância de modelos autoregressivos de ordem p, AR(p);
- Declarar o valor esperado e a variância de modelos de médias móveis de ordem q, MA(q)
- Declarar o valor esperado e a variância de modelos ARMA de ordens p e q, ARMA(p,q)

## Modelo AR(1) - valor esperado e variância

Na aula 3, calculamos valor esperado e variância do modelo AR(1). Na aula 4, o mesmo foi feito para o modelo MA(1). O quadro resume as fórmulas já obtidas nessas aulas.

**Atenção!** Aqui existe uma videoaula, acesso pelo conteúdo online

Modelo	Representação	$E(Y_t)$	$V(Y_t)$
AR(1) sem constante	$Y_t = \phi_1 Y_{t-1} + \varepsilon_t$	0	$\frac{\sigma^2}{1 - \phi_1^2}$
AR(1) com constante	$Y_t = \phi_0 + \phi_1 Y_{t-1} + \varepsilon_t$	$\frac{\phi_0}{1 - \phi_1}$	$\frac{\sigma^2}{1 - \phi_1^2}$
MA(1) sem constante	$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1}$	0	$(1 + \theta_1^2) \sigma^2$
MA(1) com constante	$Y_t = \theta_0 + \varepsilon_t - \theta_1 \varepsilon_{t-1}$	$\theta_0$	$(1 + \theta_1^2) \sigma^2$

 **Atenção!** Para visualização completa da tabela utilize a rolagem horizontal

Nesta aula apresentamos um procedimento que permite calcular o valor esperado e a variância para modelos AR de maior ordem e para a classe mais geral dos modelos ARMA. Este procedimento só é válido para modelos estacionários, ou seja, que verifiquem as condições de estacionariedade apresentadas na aula 4. Uma vez verificadas as condições, impõe-se que:

$$E(Y_t) = \mu, \forall t = 1, 2, \dots, T \text{ (média constante)}$$

$$V(Y_t) = \sigma^2, \forall t = 1, 2, \dots, T \text{ (variância constante)}$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

e aplica-se estas condições para calcular o valor esperado e variância. Na seção 4.2 vamos aplicar este método para confirmar os resultados encontrados na aula 3, para o modelo AR(1).

Como já vimos, para o modelo AR(1) sem constante:

$$Y_1 = \varepsilon_1 \left( \text{supondo } Y_0 = 0 \right) Y_2 = \phi Y_1 + \varepsilon_2 = \phi \varepsilon_1 + \varepsilon_2 Y_3 = \phi Y_2 + \varepsilon_3 = \phi \varepsilon_1 + \phi \varepsilon_2 + \varepsilon_3$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

A fórmula geral para um instante t genérico é:

$$Y_t = \sum_{i=0}^{t-1} \phi^i \varepsilon_{t-i}$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Cujo valor esperado é:

$$\sum_{i=0}^{t-1} \phi^i \varepsilon_{t-i} = \sum_{i=0}^{t-1} \phi^i E(\varepsilon_{t-i}) = 0$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

uma vez que  $E(\varepsilon_i) = 0$ , por definição.

A variância de  $(Y_t)$  é (os  $\varepsilon_i$  são descorrelacionados):

$$V(Y_t) = V\left(\sum_{i=0}^{t-1} \phi^i \varepsilon_{t-i}\right) = \sum_{i=0}^{t-1} \phi^{2i} V(\varepsilon_{t-i}) = \sum_{i=0}^{t-1} \phi^{2i} \sigma^2 = \sigma^2 \sum_{i=0}^{t-1} \phi^{2i}.$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Agora note que os termos no interior do somatório definem uma progressão geométrica:  $\phi^0, \phi^2, \phi^4, \dots$ , até  $\phi^{2(t-1)}$ , ou seja, com primeiro termo 1 (pois  $\phi^0 = 1$ ) e razão  $\phi^2$ . Lembrando agora que o somatório dos termos de uma progressão geométrica finita com  $t$  termos, sendo o primeiro termo igual a "a" e a razão igual a  $q$ , é dado por:

$$S_t = \frac{a_1 (1 - q^t)}{1 - q}$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

E notando que, no caso em questão,  $a_1 = 1$  e  $q = \phi^2$ , temos:

$$\sum_{i=0}^{t-1} \phi^{2i} = \frac{1 - \phi^{2t}}{1 - \phi^2}$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

E assim:

$$\sum_{i=0}^{t-1} \phi^{2i} = \frac{1 - \phi^{2t}}{1 - \phi^2}$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Note que, se t tende ao infinito, o resultado acima é constante desde que  $|\phi| < 1$ , caso em que o termo  $\phi^{2t}$  aproxima-se de zero. Neste caso:

$$V\left(Y_t\right) = \frac{\phi^2}{1 - \phi^2}$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Para o modelo com constante:

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \varepsilon_t$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

O valor esperado era obtido da seguinte forma:

$$Y_t = \phi_0 \sum_{i=0}^{t-1} \phi_1^i + \sum_{i=0}^{t-1} \phi_1^i \varepsilon_{t-i}, E\left(Y_t\right) = \phi_0 \sum_{i=0}^{t-1} \phi_1^i$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Quanto ao somatório, podemos aplicar a fórmula da soma da progressão geométrica:

$$\sum_{i=0}^{t-1} \phi_1^i = \frac{1 - \phi_1^t}{1 - \phi_1}.$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Aplicando à expressão obtida para o valor esperado:

$$E(Y_t) = \phi_0 \sum_{i=0}^{t-1} \phi_1^i = \phi_0 \frac{1 - \phi_1^t}{1 - \phi_1}.$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Novamente, se  $|\phi_1| < 1$ ,  $\phi_1^t$  tende a zero quanto  $t$  tende a infinito, e, neste caso:

$$E(Y_t) = \frac{\phi_0}{1 - \phi_1}.$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

E a variância:

$$V(Y_t) = \sigma^2 \sum_{i=0}^{t-1} \phi_1^{2i} = \frac{1 - \phi_1^{2t}}{1 - \phi_1^2} \sigma^2.$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Novamente, se  $t$  tende ao infinito, o resultado acima é constante desde que  $|\phi_1| < 1$ , caso em que o termo  $\phi_1^{2t}$  aproxima-se de zero. Neste caso:

$$V(Y_t) = \frac{\sigma^2}{1 - \phi^2}$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

A seguir vamos confirmar o valor esperado e a variância do AR(1). Confirmando o valor esperado do AR(1) (com constante):

$$E(Y_t) = E(\phi_0) + \phi_1 E(Y_{t-1}) + E\epsilon_t = \phi_0 + \phi_1 E(Y_{t-1}) + 0 = \phi_0 + \phi_1 E(Y_{t-1}).$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

O problema é que não conhecemos  $E(Y_{t-1})$ .

Porém, sob "estacionariedade, temos que  $E(Y_t) = E(Y_{t-1})$ .

$$\text{Daí: } E(Y_t) = \phi_0 + \phi_1 E(Y_t) \Rightarrow E(Y_t) = \frac{\phi_0}{1 - \phi_1}, \text{ como queríamos demonstrar.}$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Comentário

Perceba que o método acima é bem mais fácil do que o método recursivo adotado na aula 3. Adicionalmente, por aquele método torna-se inviável ampliar os resultados para modelos mais complexos. Utilizando a propriedade de estacionariedade, esta tarefa torna-se simples.

Confirmando a variância do AR(1) (com constante):

$$V(Y_t) = V(\phi_0) + \phi_1^2 V(Y_{t-1}) + V(\varepsilon_t) = 0 + \phi_1^2 V(Y_{t-1}) + \sigma^2, \text{ pois } \text{Cov}(Y_{t-1}, \varepsilon_t) = 0$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Novamente, o problema é que não conhecemos  $V(Y_{t-1})$ .

Porém, sob estacionariedade, temos que:  $V(Y_t) = V(Y_{t-1})$ .

$$\text{Daí: } V(Y_t) = \phi_1^2 V(Y_t) + \sigma^2 \Rightarrow V(Y_t) = \frac{\sigma^2}{1 - \phi_1^2}, \text{ como queríamos demonstrar.}$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Para provar que  $\text{Cov}(Y_{t-1}, \varepsilon_t) = 0$ , vamos usar "a forma geral do AR" (1), já derivada na aula 3. A forma geral ad:"

$$Y_t = \phi_0 (1 + \phi_1 + \phi_1^2 + \dots + \phi_1^{t-1}) + \phi_1^{t-1} \varepsilon_1 + \phi_1^{t-2} \varepsilon_2 + \dots + \varepsilon_t \text{ ou:}$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Todos os termos do lado direito desta equação apresentam correlação zero com  $\varepsilon_t$ , pois se trata de um ruído branco. Isto conclui a prova.

A seguir vamos ampliar os resultados acima para modelos de ordem superior.



**Atenção!** Aqui existe uma videoaula, acesso pelo conteúdo online

Começando pelo AR(2), representado pela seguinte equação:

$$Y_t = \phi_0 + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Assim:

$$E(Y_t) = E(\phi_0) + \phi_1 E(Y_{t-1}) + \phi_2 E(Y_{t-2}) + E(\varepsilon_t) = \phi_0 + \phi_1 E(Y_{t-1}) + \phi_2 E(Y_{t-2}) + 0 = \phi_0 + \phi_1 E(Y_{t-1}) + \phi_2 E(Y_{t-2})$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Porém, sob "estacionariedade, temos que  $Y_t = E(Y_{t-1} = Y_{t-2})$

$$\text{Daí: } E(Y_t) = \phi_0 + \phi_1 E(Y_t) + \phi_2 E(Y_t) \Rightarrow E(Y_t) = \frac{\phi_0}{1 - \phi_1 - \phi_2}$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Com contas análogas, é fácil ver que, para o caso do AR(p):

$$E(Y_t) = \frac{\phi_0}{1 - \sum_{j=1}^p \phi_j}$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

# Modelos MA(2) e MA(q)

Lembremos que o modelo MA(q) é representado pela seguinte equação:

$$Y_t = \varepsilon_t - \theta_1 \varepsilon_{tem} - \theta_2 \varepsilon_{tem}$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Como este modelo é dado por uma combinação linear dos valores correntes e defasados de um ruído branco, temos um facilitador, que são justamente as propriedades simplificadoras de um processo estocástico do tipo ruído branco, apresentadas na aula 3 e lembradas a seguir:

$$E(\varepsilon_t) = 0, \forall t, V(\varepsilon_t) = \sigma^2, \forall t, Corr(\varepsilon_i, \varepsilon_j) = 0, \forall i \neq j$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Desta forma, o uso do método proposto na seção 4.1 sequer se faz necessário, sendo imediato generalizar os resultados do modelo MA(1) obtidos na aula 4 para os modelos MA(2) e MA(q).

Lembrando que no caso do MA(1) procedemos (na aula 4) da seguinte forma:

$$E(Y_t) = 0 \text{ (sem constante adicionada) ou } \theta_0 \text{ (com constante } \theta_0 \text{)}. V(Y_t) = V(\varepsilon_t) + \theta_1^2 V(\varepsilon_t), \text{ pois } Cov(\varepsilon_t, \varepsilon_t, 0) = 0.$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Desta forma:

$$V(Y_t) = \sigma^2 + \theta_1^2 \sigma^2 + \theta_2^2 \sigma^2 = (1 + \theta_1^2 + \theta_2^2) \sigma^2$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

É fácil generalizar a fórmula acima para o modelo MA(q):

$$V(Y_t) = (1 + \sum_{j=1}^q \theta_j^2) \sigma^2$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

A presença de uma constante  $\theta_0$  não altera em nada os resultados para a variância.

Considere o seguinte modelo MA(2):

$$Y_t = \varepsilon_t - 0.6\varepsilon_{t-1} - 0.3\varepsilon_{t-2}, \quad \varepsilon_t \stackrel{i.i.d}{\sim} N(0, 2), \quad \forall t$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Determine o valor esperado e a variância deste modelo.

$$E(Y_t) = 0 \quad (\text{pois não há constante adicionada}) \quad V(Y_t) = (1 + \theta_1^2 + \theta_2^2) \sigma^2 = (1 + (0.6)^2 + (0.3)^2) \cdot 2^2 \cdot 1.45 \cdot 4 = 5$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

## Modelo ARMA(1,1)

A equação do ARMA(1,1) é lembrada a seguir:

**Atenção!** Aqui existe uma videoaula, acesso pelo conteúdo online

$$Y_t = \phi_1 Y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Seguindo a lógica do que já foi feito para o caso do modelo AR(1), lembrando que  $E(\varepsilon_t) = 0, \forall t$ , mostra-se facilmente que:

$$E(Y_t) = \frac{\phi_0}{1 - \phi_1},$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

resultado este que também valeria para um ARMA(1,q),  $q > 1$ .

Já para um ARMA(p,q), pode-se mostrar de forma muito simples que:

$$E(Y_t) = \frac{\phi_0}{1 - \sum_{j=1}^p \phi_j},$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

O cálculo da variância do modelo ARMA(1,1) envolve um algebrismo mais complexo, mostrado a seguir.

Primeiramente, para calcular  $V(\phi_1 Y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1})$ , deve-se levar em conta que  $Y_{t-1}$  e  $\varepsilon_{t-1}$  são correlacionados, e assim será útil o seguinte resultado da teoria da probabilidade:

Seja  $C = aX + bY$ , uma combinação linear de duas variáveis aleatórias  $X$  e  $Y$ , em que  $a$  e  $b$  são constantes. Então, pode-se provar que:

$$V(C) = a^2V(X) + b^2V(Y) + 2abCov(X,Y).$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Primeiramente, verifica-se que nem  $Y_{t-1}$  nem  $\varepsilon_{t-1}$  apresentam correlação com  $\varepsilon_t$ . Desta forma:

$$V(\phi_1 Y_{t-1} + \varepsilon_t + \phi_2 \varepsilon_{t-1}) = V(\phi_1 Y_{t-1} + \phi_2 \varepsilon_{t-1}) + V(\varepsilon_t)$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Agora, para calcular  $V(\phi_1 Y_{tgo} + g_1 \varepsilon_{tgo})$ , é necessário aplicar a fórmula de  $V(C)$ , usando  $X = Y_{t-1}$ ,  $Y = \varepsilon_t$ ,  $a = \phi_1$  e  $b = g_1$ . Teremos como resultado:

$$V(\phi_1 Y_{t-1} + g_1 \varepsilon_t) = \phi_1^2 V(Y_{t-1}) + g_1^2 V(\varepsilon_t) - 2\phi_1 g_1 Cov(Y_{t-1}, \varepsilon_t)$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Lembrando agora que  $V(\varepsilon_t) = \sigma^2$ ,  $\forall t$ , temos:

$$V(Y_t) = \phi_1^2 V(Y_{t-1}) + \theta_1^2 \sigma^2 - 2\phi_1 \theta_1 Cov(Y_{t-1}, \varepsilon_t) + \sigma^2$$



**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Lembrando agora que  $Cov(Y_{t-1}, \varepsilon_t)$  é apresentado a seguir.

$$V(Y_t) = \varphi_1^2 V(Y_{t-1}) + \theta_1^2 \sigma^2 - \varphi_1 \theta_1 \text{Cov}(Y_{t-1}, \varepsilon_{t-1}) + \sigma^2 \text{Cov}(Y_{t-1}, \varepsilon_{t-1}) = \text{Cov}(\varphi_1 Y_{t-1} + \varepsilon_{t-1} - \theta_1 \varepsilon_{t-1}, \varepsilon_{t-1}) = \text{Cov}(\varepsilon_{t-1}, \varepsilon_{t-1}) = V(\varepsilon_{t-1})$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Finalmente, sob "estacionariedade", temos:  $V(Y_t) = V(Y_{t-s})$

Assim:

$$V(Y_t) = \varphi_1^2 V(Y_t) + \sigma^2 + \theta_1^2 \sigma^2 - \varphi_1 \theta_1 \sigma^2 \Rightarrow V(Y_t) = \frac{1 + \theta_1^2 - \varphi_1 \theta_1}{1 - \varphi_1^2} \sigma^2$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Uma "pegadinha" comum em concursos públicos costuma ser a apresentação da fórmula acima sem considerar o termo da covariância na demonstração, o que resultaria em:

$$V(Y_t) = \frac{1 + \theta_1^2}{1 - \varphi_1^2} \sigma^2$$

 **Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Finalmente, note que uma constante adicionada ao modelo não alteraria a sua variância.

Vamos ver um exemplo? **Considere o seguinte modelo ARMA(1,1):**

esperado e a variância deste modelo. Solução:  $E(Y_t) = \frac{\phi_0}{1 - \phi_1} = \frac{0.2}{0.5} = 0.4$   $V(Y_t) = \frac{1 + (-0.5)^2 + (0.5)(-0.5)}{1 - \phi_1^2} 4 = \frac{2.44}{0.75} 4 = \cong 13.$




**Atenção!** Para visualização completa da equação utilize a rolagem horizontal

Estamos aptos agora a ampliar o quadro do início da aula para incorporar os novos resultados:

Modelo	Representação	$E(Y_t)$	$V(Y_t)$
AR(1) sem constante	$Y_t = \phi_1 Y_{t-1} + \varepsilon_t$	0	$\frac{\sigma^2}{1 - \phi_1^2}$
AR(1) com constante	$Y_t = \phi_0 + \phi_1 Y_{t-1} + \varepsilon_t$	$\frac{\phi_0}{1 - \phi_1}$	$\frac{\sigma^2}{1 - \phi_1^2}$
MA(1) sem constante	$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1}$	0	$(1 + \theta_1^2) \sigma^2$
MA(1) com constante	$Y_t = \theta_0 + \varepsilon_t - \theta_1 \varepsilon_{t-1}$	$\theta_0$	$(1 + \theta_1^2) \sigma^2$
AR(2) sem constante	$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t$	0	*
AR(2) com constante	$Y_t = \phi_0 + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t$	$\frac{\phi_0}{1 - \phi_1 - \phi_2}$	*
MA(2) sem constante	$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2}$	0	$(1 + \theta_1^2 + \theta_2^2) \sigma^2$
MA(2) com constante	$Y_t = \theta_0 + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2}$	$\theta_0$	$(1 + \theta_1^2 + \theta_2^2) \sigma^2$
AR(p) sem constante	$Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \varepsilon_t$	0	*
AR(p) com constante	$Y_t = \phi_0 + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \varepsilon_t$	$\frac{\phi_0}{1 - \phi_1 - \dots - \phi_p}$	*
MA(q) sem constante	$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$	0	$(1 + \theta_1^2 + \dots + \theta_q^2) \sigma^2$
MA(q) com constante	$Y_t = \theta_0 + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$	$\theta_0$	$(1 + \theta_1^2 + \dots + \theta_q^2) \sigma^2$
ARMA(1,1) sem constante	$Y_t = \phi_1 Y_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}$	0	$\frac{1 + \theta_1^2 - \phi_1 \theta_1}{1 - \phi_1^2} \sigma^2$
ARMA(1,1) com constante	$Y_t = \phi_0 + \phi_1 Y_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}$	$\frac{\phi_0}{1 - \phi_1}$	$\frac{1 + \theta_1^2 - \phi_1 \theta_1}{1 - \phi_1^2} \sigma^2$

O cálculo da variância desses modelos envolve álgebra, o que foge ao escopo deste material e será deixado como extensão.

Observe a série a seguir. Qual ou quais dos modelos do quadro você poderia descartar para representá-la?





## Atividade

A média do modelo  $Y_t = 3 + 0.5Y_{t-1} + \varepsilon_t$  em que  $\varepsilon_t \stackrel{i.i.d}{\sim} N(0, 1)$ ,  $\forall t$ , é:


- a) 0
- b) 1.5
- c) 3
- d) 6
- e) 8

## Atividade

A variância do modelo  $Y_t = 3 + \varepsilon_t - 0.5\varepsilon_{t-1}$  em que  $\varepsilon_t \stackrel{i.i.d}{\sim} N(0, 4)$ ,  $\forall t$ , é:

- a) 3
- b) 5
- c) 8
- d) 6
- e) 12

A seguir temos a série anual da produção de carvão betuminoso nos Estados Unidos entre os anos 1920 e 1968.



Qual dos seguintes modelos seria um candidato a representar esta série?

- a) Passeio aleatório simples
  - b) Passeio aleatório com constante
  - c) AR(1) estacionário sem constante
  - d) AR(1) estacionário com constante
  - e) Nenhuma das alternativas acima
- 

## Notas

### Título modal <sup>1</sup>

---

Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos. Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos. Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos.

### Título modal <sup>1</sup>

---

Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos. Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos. Lorem Ipsum é simplesmente uma simulação de texto da indústria tipográfica e de impressos.

## Referências

---

BOX, G.E.P.; JENKINS, G.M. **Time series analysis**: Forecasting and control. San Francisco: Holden-Day, Inc., 1976.

BROCKWELL, P.J.; DAVIS, R.A. **Time Series**, Theory and Methods, 2nd ed., Springer, 2009.

CAMPBELL, M.J.; WALKER, A.M. A Survey of Statistical Work on the Mackenzie River Series of Annual Canadian Lynx Trappings for the Years 1821-1934 and a New Analysis. **Journal of the Royal Statistical Society**. Series A (General), v. 140, n. 4, p. 411–431, 28 ago. 1977.

HARVEY, A.C. **Forecasting, Structural Time Series Models and the Kalman Filter**. Cambridge: Cambridge University Press, 1990.

HYNDMAN, R.J.; ATHANASOPOULOS, G. **Forecasting**: principles and practice. 2nd. ed. Melbourne.

MAKRIDAKIS, S.; WHEELWRIGHT, S.C.; HYNDMAN, R.J. **Forecasting**: methods and applications. New York: John Wiley & Sons, 1998.

MORETTIN, P.A.; TOLOI, C.M.C. **Análise de séries temporais**. São Paulo: Edgard Blucher, 2004.

- Funções de autocorrelação e de autocorrelação parcial.

## Explore mais

---

- Leia o texto Análise de Séries Temporais: <http://www.each.usp.br/rvicente/AnaliseDeSeriesTemporais.pdf>.